

Quando 2,4 milhões de respostas não bastam

O erro da Literary Digest em 1936: diagnóstico de viés e correção por regressão linear com âncora em 1932

[Nome da equipe e integrantes: preencher] · Universidade de Mogi das Cruzes (UMC) · Summit UMC

1. O caso de 1936

A revista *The Literary Digest* enviou **10 milhões** de cartões e recebeu **2,4 milhões** de respostas. Previu a vitória de Landon, mas **Roosevelt venceu com 62%** dos votos e a revista faliu. Nosso papel: cientistas de dados forenses.

57,1%

Landon segundo a pesquisa

37,5%

Landon nas urnas

+19,6


pontos percentuais de erro

A pesquisa deu **370 votos eleitorais** a Landon; ele obteve **8**. Errou o vencedor em **30 de 48 estados** e superestimou Landon em **48 de 48**.

2. Dados e método

- 1 Limpeza (Pandas).** 48 estados, 4 blocos unidos pelo nome do estado, traços tratados e totais conferidos.
- 2 Exploração (NumPy).** Voto republicano entre os dois partidos; erro = pesquisa – real.
- 3 Diagnóstico de viés.** O “voto em 1932” dos respondentes contra o resultado real de 1932.
- 4 Modelo (Scikit-Learn).** Regressão linear simples: erro de 1936 = $a + b \cdot \text{viés de 1932}$. Validação leave-one-out.

3. Diagnóstico de viés




Em 1932 a pesquisa acertou (erro de 0,7 pp). Em 1936, errou por 19,6 pp.

51,4%

dos respondentes diziam ter votado em Hoover em 1932...

40,9%


...contra a votação real: viés de amostragem de 10,6 pp



Cada ponto é um estado: **quanto mais republicana a amostra em 1932, maior o erro em 1936** ($r = 0,91$).

Não-resposta: só 23,8% dos cartões voltaram; os outros 76% teriam de ser **25,7 pp menos republicanos** que quem respondeu (cenário hipotético).

4. Correção com âncora em 1932



Cada ponto é um estado. Modelo: **erro de 1936 = 9,0 pp + 0,99 × viés de 1932**; previsão corrigida = pesquisa – erro previsto.

Abordagem	Erro médio (pp)	Estados certos	Votos Landon	Landon no país
Pesquisa bruta	18,6	18/48	370	56,9%
Correção ingênua (1932)	17,1	18/48	338	56,9%
Regressão com âncora	2,6	48/48	8	38,4%
Só o real de 1932	3,5	48/48	8	38,3%
Resultado real	–	–	8	37,5%

Regressão e referência: previsões estado a estado por validação leave-one-out.

–86%

no erro médio por estado: de 18,6 para **2,6 pp**, e o vencedor certo em 48 de 48 estados.

Volume não é representatividade

2,4 milhões de respostas e 20 pontos de erro: mais dados do mesmo viés não o corrigem.

Quem falta nos dados é mal previsto

Crédito, saúde e reconhecimento facial treinados com populações pouco diversas correm o mesmo risco.

Use uma âncora externa

Comparar a amostra com um resultado conhecido (aqui, 1932) revelou o viés e permitiu corrigi-lo.

Documente e audite

Medir cobertura, auditar por grupo e reportar limitações são deveres éticos da engenharia de dados.