

Hackathon de Ciência de Dados: O Desafio de 1936

Regulamento Oficial, Diretrizes Metodológicas e Requisitos de Entrega (Summit UMC)

1. Contextualização do Desafio

Em 1936, a revista *The Literary Digest* conduziu a maior pesquisa de intenção de voto da história até então, enviando 10 milhões de cartões postais e recebendo quase **2,4 milhões de respostas**. Com base nesse colossal "Big Data", a publicação previu uma vitória esmagadora do candidato republicano Alf Landon (57% contra 43%). No entanto, Franklin D. Roosevelt venceu com 62% dos votos populares, resultando no maior desastre preditivo da história estatística e levando a revista à falência[cite: 1, 2, 4].

O objetivo deste hackathon é colocar os estudantes no papel de cientistas de dados forenses para investigar as causas do erro, limpar os dados históricos e aplicar modelos preditivos fundamentais utilizando **Pandas, NumPy e Scikit-Learn**.

2. Trilha de Tarefas e Nível Técnico

A atividade foi desenhada para estudantes iniciantes e contempla quatro etapas progressivas:

- Limpeza e Preparação de Dados (Data Wrangling):** Carregar a base de dados em Excel, tratar valores ausentes e padronizar colunas com Pandas.
- Análise Exploratória e Estatística Descritiva:** Utilizar NumPy e Pandas para calcular proporções de votos e mensurar discrepâncias estaduais.
- Diagnóstico de Viés:** Identificar e quantificar o viés de amostragem e o viés de não-resposta através de visualizações simples.
- Modelagem Preditiva Básica:** Construir um modelo de Regressão Linear simples com Scikit-Learn utilizando o comportamento eleitoral passado (1932) como âncora para corrigir as previsões de 1936[cite: 1, 2].

3. Cronograma e Fases da Competição

Fase	Atividade Principal	Entregável
Fase 1	Análise exploratória inicial e limpeza de dados (Python/Jupyter).	Notebook Jupyter estruturado.
Fase 2	Implementação do modelo de correção e análise dos resultados estaduais.	Script funcional com métricas de erro.
Fase 3	Redação do Resumo Acadêmico nos moldes do Summit da UMC.	Abstract formatado (PDF/Doc).
Fase 4	Elaboração do Pôster Científico para apresentação final.	Pôster digital (PDF).

4. Critérios de Avaliação

- Rigor Técnico e Código (35%):** Funcionamento correto do código em Python, uso adequado de Pandas/NumPy e clareza na aplicação do modelo Scikit-Learn.
- Interpretação Estatística (25%):** Capacidade de explicar o viés de amostragem e a eficácia da correção aplicada.
- Qualidade do Resumo - Summit UMC (20%):** Clareza, estrutura acadêmica e aderência às normas exigidas pelo evento.

- **Design e Apresentação do Pôster (20%):** Organização visual, poder de síntese e comunicação científica dos resultados.

5. Entregáveis Finais Obrigatórios

Ao término do hackathon, cada equipe deverá submeter os seguintes artefatos:

1. **Jupyter Notebook (.ipynb):** Código comentado contendo todas as etapas de manipulação e modelagem.
2. **Resumo Acadêmico (Padrão Summit UMC):** Documento de até 500 palavras estruturado com: *Introdução*, *Metodologia*, *Resultados e Discussão*, e *Conclusão*, destacando a conexão entre o erro histórico de 1936 e os desafios éticos de IA na atualidade[cite: 2].
3. **Pôster Científico Digital:** Layout visual resumindo o estudo de caso, a metodologia de correção e as principais lições aprendidas para a engenharia de dados moderna.